



Universidad de Deusto
Deustuko Unibertsitatea

Fundamentos del Procesamiento de Lenguaje Natural - Entrega 1

Entrega E1
Propuesta de Proyecto

Arambarri Urresti, Ibon - 46366616L
Milla Tinajero, Alejandro - 50592045A

25/09/2025

Índice:

1. Abstract:.....	3
2. Análisis de los datasets: Acceso al dataset.....	4
3. Related work:.....	5
3.1 Análisis de Sentimiento Financiero.....	5
3.2 Detección de Consistencia Interna.....	5
3.3 Normalización Lingüística.....	5
3.4 Sistemas Integrados.....	5
3.5 Limitaciones Identificadas.....	5
4. Bibliografía.....	6

1. Abstract:

Nuestro objetivo principal trata de comprobar la consistencia de ciertas noticias relacionadas con mercados financieros para su posterior análisis de sentimiento y traducción al inglés. Con esto queremos conseguir una herramienta capaz de filtrar entre el humo de las fake news y dar una aproximación del estado en el que se encuentra el mercado. La traducción al inglés es un requisito imprescindible para estandarizar el idioma de todas las noticias para su posterior análisis.

En cuanto a las tareas de NLP que usaremos para llevar a cabo este proyecto tenemos:

- **Normalización lingüística:** Usaremos un modelo NMT o LLM (aún por especificar) para tener la capacidad de traducir las noticias al inglés.
- **Detección de consistencia interna:** De esta manera utilizaremos un modelo NLI para detectar si se trata de una noticia que es coherente en su totalidad o está mezclada con fragmentos inconexos.
- **Análisis de sentimiento:** Utilizaremos un transformer pre entrenado BERT como modelo base, sobre el cual realizaremos fine-tuning específico para el dominio financiero. El modelo será entrenado para clasificar las noticias en tres categorías de sentimiento (positivo, negativo y neutral).

Para la evaluación, aplicaremos los siguientes criterios y métodos de evaluación:

- **Normalización lingüística:** Para la traducción, hemos optado por usar COMET, ya que es una métrica neuronal moderna y correlaciona mejor con juicio humano. Pero también aprovechamos el hecho de tener las noticias en el idioma “original” y en inglés, para evaluar la traducción de nuestro modelo.
- **Detección de consistencia interna y Análisis de sentimiento:** Ya que estos al fin y al cabo son unos clasificadores, podemos usar métricas comunes en ML como: Accuracy, F1-score en clasificación de consistencia. También tenemos la opción de usar una Matriz de Confusión para visualizar errores sistemáticos.

2. Análisis de los datasets: [Acceso al dataset](#)

Hemos optado por escoger este dataset debido a que cumple con las necesidades que requiere nuestro trabajo. Consta de 5322 noticias en inglés (primera columna) con su respectivo valor de sentimiento (segunda columna).

La primera columna trata de un campo de texto “Sentence” el cual guarda la noticia y la segunda columna “Sentiment” clasifica la noticia según el sentimiento que evoque. En cuanto a la distribución de los targets y opciones de clasificación de esta segunda columna el dataset nos muestra: neutral 54%, positive 32%, negative 15%

Como primer paso necesitamos preprocesar los datos para obtener las noticias en diferentes idiomas, de esta manera podremos realizar la normalización lingüística para traducir las noticias de cualquier parte del mundo al inglés (idioma estándar elegido).

Como segundo paso, necesitamos crear un nuevo dataset para el modelo de Detección de consistencia. Para ello mezclaremos diferentes fragmentos de diferentes noticias en un intento de crear noticias inconsistentes pero con un origen real. Automatizamos este proceso con un script de python que aleatoriamente creará fragmentos de noticias para posteriormente juntarlas entre sí creando el dataset de noticias inconsistentes.

3. Related work:

3.1 Análisis de Sentimiento Financiero

Araci (2019) introduce FinBERT, el primer modelo BERT especializado para finanzas, logrando 88% accuracy en Financial PhraseBank. Shen et al. (2024) demuestran que GPT-4o con few-shot learning puede competir efectivamente (86% accuracy) con modelos fine-tuneados específicos. Trabajos recientes muestran aplicaciones exitosas en trading algorítmico con ratios Sharpe superiores a 3.0.

3.2 Detección de Consistencia Interna

Laban et al. (2022) desarrollan SummaC para detección de inconsistencias usando NLI, logrando 74.4% balanced accuracy mediante segmentación de oraciones. Yang et al. (2019) aplican NLI a fake news detection con 88% accuracy usando ensemble de modelos. VERITAS-NLI (2024) combina NLI con web scraping para verificación en tiempo real, alcanzando 84.3% precisión.

3.3 Normalización Lingüística

Rei et al. (2020) introducen COMET como métrica de evaluación MT superior a BLEU por su correlación con juicio humano. Estudios recientes confirman la efectividad de LLMs como ChatGPT para traducción de textos financieros especializados con pocos ejemplos de dominio.

3.4 Sistemas Integrados

Liu et al. (2025) desarrollan FMDLlama, primer LLM específico para detección de desinformación financiera, superando a GPT-4 en tareas especializadas. Los enfoques multi-etapa combinando análisis textual, visual y cross-modal muestran mayor robustez que sistemas unitaria.

3.5 Limitaciones Identificadas

Los principales desafíos incluyen escalabilidad computacional, interpretabilidad de LLMs, y limitado rendimiento zero-shot sin contextualización adecuada.

4. Bibliografía

Araci, D. (2019). FinBERT: Financial sentiment analysis with pre-trained language models. arXiv preprint arXiv:1908.10063.

Laban, P., Schnabel, T., Bennett, P. N., & Hearst, M. A. (2022). SummaC: Re-visiting NLI-based models for inconsistency detection in summarization. Transactions of the Association for Computational Linguistics, 10, 163-177.

Rei, R., Stewart, C., Farinha, A. C., & Lavie, A. (2020). COMET: A neural framework for MT evaluation. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP) (pp. 2685-2702).

Shen, Y., & Zhang, P. K. (2024). Financial sentiment analysis on news and reports using large language models and FinBERT. arXiv preprint arXiv:2410.01987.